Optionaler Zusatz: Verschiedene Datentypen in R

In R gibt es verschiedene Datentypen mit unterschiedlichen Eigenschaften. Der Datentyp bestimmt, wie Daten gespeichert und weiterverarbeitet werden können.

Vektoren

Vektoren sind die grundlegende Datenstruktur in R.

Ein Vektor ist eine Sammlung von Elementen gleichen Typs. Alle Elemente eines Vektors müssen den gleichen Datentyp (z.B. numeric) haben.

Wie in Hands-on 1 bereits besprochen, gibt es unterschiedliche Arten von Vektoren:

- Numerisch: Zahlen (umfasst *integer* und *double*)
- Character: Text (muss in Anführungszeichen gesetzt werden)
- Logisch: TRUE oder FALSE

Erstellung von Vektoren

Ein Vektor kann in R einfach mithilfe der Funktion c() (combine / concatenate) erstellt werden:

```r
numeric_vector <- c(5, 4, 5)
character_vector <- c("Frau", "Mann","Non-Binär")
logical_vector <- c(TRUE, FALSE, TRUE)
```

Ein Sonderfall eines Vektors ist ein Skalar, welcher nur ein Element beinhaltet:

```r
x <- 5
```

Werden Typen jedoch trotzdem vermischt, werden alle Elemente in denselben Typ umgewandelt; auch dann, wenn sie einzeln betrachtet eigentlich nicht zu diesem Typ gehören würden.

```r
vermischter_vektor <- c(2, 1, "mann", TRUE)
class(vermischter_vektor)
```

```
[1] "character"
```

```r
class(vermischter_vektor[1])
```

```
[1] "character"
```

Eigenschaften von Vektoren können bspw. mit typeof(), length() oder attributes() eingesehen werden.

Matrizen

Eine Matrix ist eine zweidimensionale Datenstruktur. Sie besteht aus Zeilen und Spalten.

Wichtig ist, dass bei einer Matrix alle Elemente den gleichen Datentyp haben müssen.

Eine Matrix ist also eigentlich nichts anderes als ein Vektor mit Dimensionen.

Erstellung einer Matrix

```r
v <- 1:20
dim(v) <- c(2, 10) # Als Attribut des Vektors
v
```

```
     [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10]
[1,]    1    3    5    7    9   11   13   15   17    19
[2,]    2    4    6    8   10   12   14   16   18    20
```

```r
attributes(v)    # zeigt die Dimensionen
```

```
$dim
[1]  2 10
```

Eine Matrix kann auch direkt mithilfe der Funktion matrix() erstellt werden:

```r
m <- matrix(1:20, nrow = 2, ncol = 10)
```

Zugriff auf Elemente

Objektname[Zeile, Spalte]

```r
m[2, 4]
m[2, 1:5]
```

Listen

Eine Liste ist eine flexible Datenstruktur in R. Sie kann Elemente unterschiedlicher Typen enthalten (z.B. Zahlen, Text, Vektoren, Data Frames, andere Listen).

Erstellung einer Liste

```r
my_list <- list(
  name = "Anna",
  age = 27,
  scores = c(8, 9, 10),
  info = list(city = "Bern", student = TRUE)
)

my_list
```

```
$name
[1] "Anna"

$age
[1] 27

$scores
[1]  8  9 10

$info
$info$city
[1] "Bern"

$info$student
[1] TRUE
```

Zugriff auf Listenelemente

Mit [ ] erhalten wir eine Teilliste der ursprünglichen Liste:

```r
my_list[1]
```

```
$name
[1] "Anna"
```

Das Ergebnis bleibt eine Liste.

Mit [[ ]] können wir ein einzelnes Element aus einer Liste extrahieren:

```
my_list[[3]]
```

```
[1]  8  9 10
```

```
my_list[[3]][2]
```

```
[1] 9
```

Das Ergebnis ist somit das eigentliche Element innerhalb einer Teilliste.

Mit $ können wir direkt über den Namen eines Elements zugreifen:

```
my_list$info
```

```
$city
[1] "Bern"

$student
[1] TRUE
```

```
my_list$info$student
```

```
[1] TRUE
```

Dies ist besonders praktisch bei benannten Listen.

Elemente hinzufügen

Wir können einer bestehenden Liste mit [[ ]] ein neues Element hinzufügen:

```
my_list[[5]] <- 42
my_list
```

```
$name
[1] "Anna"

$age
[1] 27

$scores
[1]  8  9 10

$info
$info$city
[1] "Bern"

$info$student
[1] TRUE


[[5]]
[1] 42
```

Alternativ kann das auch direkt über $ und einen neuen Namen erfolgen:

```
my_list$new_value <- 42
my_list
```

```
$name
[1] "Anna"

$age
[1] 27

$scores
[1]  8  9 10

$info
$info$city
[1] "Bern"

$info$student
[1] TRUE


[[5]]
[1] 42

$new_value
[1] 42
```

Listen können beliebig erweitert werden. Neue Elemente werden über einen Index oder Namen hinzugefügt.

Data Frames

Ein Data Frame ist eine tabellarische Datenstruktur. Sie besteht aus Zeilen und Spalten. Jede Spalte wiederum ist ein Vektor.

Die Spalten können unterschiedliche Datentypen beinhalten. Alle Spalten eines Data Frames müssen aber gleich viele Elemente enthalten.

Sie sind das Standardformat für Daten in R. Die Datensätze werden beim Einlesen meist direkt als Data Frame gespeichert.

Erstellung eines Data Frames

```r
bundesraet_innen <- data.frame(
  vorname = c("Elisabeth", "Martin", "Ignazio"),
  alter = c(62, 63, 65),
  partei = c("SP", "Mitte", "FDP"),
  graue_haare = c(TRUE, TRUE, FALSE)
)
```

Zugriff auf Spalten

```r
bundesraet_innen$graue_haare
```

```
[1]  TRUE  TRUE FALSE
```

Filtern von Daten

```r
library(tidyverse)

brs_unter_63 <- filter(bundesraet_innen, alter < 63)
head(brs_unter_63)
```

```
    vorname alter partei graue_haare
1 Elisabeth    62     SP        TRUE
```

Neue Variable erstellen

```r
bundesraet_innen$alter_in_10_jahren <- bundesraet_innen$alter + 10
head(bundesraet_innen)
```

```
    vorname alter partei graue_haare alter_in_10_jahren
1 Elisabeth    62     SP        TRUE                72
2    Martin    63  Mitte        TRUE                73
3   Ignazio    65    FDP       FALSE                75
```